

概率预测组合文献 (二)

主要关注内容：组合权重的估计——由固定权重转向时变（动态）权重

Combining Forecast Densities from VARs with Uncertain Instabilities (Jore et al. , 2010)

- **组合方式：**

依然是线性组合，但是权重初步考虑了时间的影响：

$$p_\tau(y_{\tau,h}) = \sum_{i=1}^N w_{i,\tau,h} g(y_{\tau,h} | I_{i,\tau}), \quad \tau = \underline{\tau}, \dots, \bar{\tau}$$

这里权重被称作“递归对数分数权重” (recursive logarithmic score weights) ，定义为前第10期到最近观测期的对数分数占比：

$$w_{i,\tau,h} = \frac{\exp \left[\sum_{\underline{\tau}-10}^{\tau-1-h} \ln g(y_{\tau,h} | I_{i,\tau}) \right]}{\sum_{i=1}^N \exp \left[\sum_{\underline{\tau}-10}^{\tau-1-h} \ln g(y_{\tau,h} | I_{i,\tau}) \right]}, \quad \tau = \underline{\tau}, \dots, \bar{\tau}$$

- **组合实证：**

数据与方法：估计美国产出、通胀、短期利率的模型，数据为1965Q4-2005Q4的季度数据，个体模型为AR及VAR类（8种），数据划分与Clark 和 McCracken (2008) 的研究保持一致以保证可比性。组合策略还考虑了等权组合的方法。实验结果主要是考察与PIT（概率积分变换）相关的正态性检验，进而评估拟合优度。

实证结论：

1. 点预测与区间预测的不同：基准的AR方法及CM (2008) 推荐的点预测方法几乎没有证据支持有利于组合预测（权重偏小甚至为0）；相关的统计检验也支持上述结论。
2. 在概率校准 (Calibration) 检验方面，等权 (EW) 与本文提出的递归权重 (RW) 大多数时候表现相当，但在1985-2005时间段EW稍差；其它方法在此方面不如这两个组合方法。

此外，在Nowcasting GDP in Real Time: A Density Combination Approach (Aastveit et al., 2014) 一文中，也利用了相同的权重设置，而个体方法改为Bridge、Dynamic Factor Models、MF-VAR三种方法，对美国1990Q2到2010Q3的GDP数据进行预测，在对数分数和校准检验两方面进一步验证了RW权重相对与个体方法的优势。

Confronting Model Misspecification in Macroeconomics (Waggoner, Zha, 2012)

- **组合方式：**

使用马尔可夫状态切换机制决定两个模型权重如何变化。两个个体模型分别是DSGE（动态随机一般均衡，参数化较紧密）和BVAR（贝叶斯向量自回归，参数化较松散）。其组合预测如下所示：

$$p(y_t | Y_{t-1}^o, \Theta, Q, w, s_t) = \sum_{i=1}^n w_{i,s_t} p(y_t | Y_{t-1}^o, \Theta_i, M_i)$$

其中 Y 指观测数据， Θ 指个体模型参数， Q 指状态转移矩阵， s_t 指不可观测的状态（服从马尔可夫链）。

这里作者选择将参数、转移矩阵与权重同时进行估计，通过最大化后验以及 Gibbs、MCMC 等方法来估计参数与权重。（最终的估计结果是：估计出两个状态，每个状态有一个固定的权重分配，模型组合在这两个状态中选一个。）

$$\log p(Y_T^o | \Theta, Q, w) = \sum_{t=1}^T \log p(y_t^o | Y_{t-1}^o, \Theta, Q, w)$$

$$p(\Theta, Q, w | Y_T^o) \propto p(Y_T^o | \Theta, Q, w) p(\Theta, Q, w)$$

- **组合实证：**

数据：宏观经济数据（1960-2010）

方法：个体方法、等权组合、马尔可夫切换的对比，参考指标为对数MDD（边际数据密度）、LPS（对数预测分数）、LCPL（对数集中预测似然）。

结论：等权组合已经带来了较大提升，而马尔可夫切换在此基础上进一步提升（适应不同的冲击）。文章还用大量篇幅讨论了如何基于可解释的DSGE来讨论如何从组合结果中分析外生冲击的影响（可解释性研究）。

Generalised density forecast combinations (Kapetanios et al., 2015)

- **组合方式：**

提出了“广义意见池”（Generalised opinion pool）的概念，每个方法的权重时变。

$$p_t(y) = \sum_{i=1}^N w_{it}(y) q_{it}(y)$$

such that

$$\int p_t(y) dy = 1,$$

为了能解出权重，文中将权重表示成基函数回归的形式，以解决最小化损失问题。

$$\begin{aligned} \Phi_{q_i}^T &= \left\{ w_{T\eta i}(.): w_{T\eta i}(.) = \tilde{v}_{i0} + \sum_{s=1}^{p_T} \tilde{v}_{is} \eta_s(y, \boldsymbol{\theta}_s), \right. \\ &\quad \left. \tilde{v}_{is} \geq 0, \eta_s(y, \boldsymbol{\theta}_s) \geq 0 \right\}, \quad i = 1, \dots, N, \end{aligned}$$

权重的时变性基于基回归系数 v 的标准化实现：

$$\tilde{v}_{it0} = \tilde{v}_t(v_{i0}; \mathbf{v}_i^{(-0)}) = \tilde{v}_t(v_{i0}) = \frac{v_{i0}}{\sum_{i=1}^N \left(v_{i0} + \sum_{s=1}^{p_T} v_{is} K_{its} \right)}$$

$$\tilde{v}_{its} = \tilde{v}_t(v_{is}; \mathbf{v}_i^{(-s)}) = \tilde{v}_t(v_{is}) = \frac{v_{is}}{\sum_{i=1}^N \left(v_{i0} + \sum_{s=1}^{p_T} v_{is} K_{its} \right)},$$

基的个数作者建议通过交叉验证选取；基的形式作者认为可以有多种设置，文中用的是分段回归的基函数（分段示性函数）。而分段的边界如果不事先指定，通过网格搜索解决。损失函数仍是对数分数（再加负号）。

（分段线性回归可能带来不光滑的性质，文中也提出了一种改进措施来缓解这一问题，以得到更光滑的密度）

- **方法说明：**

权重的一致性：证明了在一定假设下，权重基回归的参数 v 和 θ 满足渐进正态性，依概率收敛到真值；

回归系数 v 的估计也可证明具有相合性、渐进正态性。

- **组合实证：**

该文章进行了模拟实验与实证实验。

蒙特卡洛模拟：做了四个实验以考察对错误指定的模型的改进：1.真实密度非正态，用基于正态的广义线性组合去捕捉非正态分布；2.真实密度正态，用两个错误指定的正态组合分析组合改进能力；3.考虑门限自回归模型，评估不同自回归参数线性正态模型组合逼近非线性过程的能力；4.真实密度随时间演变，其根据一个带随机波动的不可观测成分趋势周期模型而变化（现实背景是美国的通货膨胀），考察两个没有随机波动的模型组合预测能力。将广义池与线性池做比较。

实证分析：使用 S&P500 在1972.1.3-2013.9.9每日对数回报率数据，对标 John Geweke 与 Gianni Amisano (2011) 的结果。个体模型为 GARCH, T-GARCH, E-GARCH, SV四种，尝试2模型、3模型、4模型组合。将广义池与线性池做比较。

结论：模拟与实证的结果证明对数情况下广义池的优越性；此外的发现是，**交叉验证可以避免过拟合**（倾向于少分段）；**广义池更适用于大样本**（因其需要参数更多，故需要更长时间的数据）；在实证中作者的建议是**对复杂的组合使用简单的权重估计形式**（少分段）；以及**个体模型数不是越多越好**；同时其还发现线性池在样本外可以但通常不会胜过所有个体模型的预测结果。

Dynamic prediction pools: An investigation of financial frictions and forecasting performance

(Del Negro et al., 2016)

- **组合方式：**

动态池，依然是线性组合，下式是联合概率：

$$p(y_{1:T} | \lambda_{1:T}, \mathcal{P}) = \prod_{t=1}^T \{ \lambda_t p(y_t | y_{1:t-1}, \mathcal{M}_1) + (1 - \lambda_t) p(y_t | y_{1:t-1}, \mathcal{M}_2) \}, \quad \lambda_t \in [0, 1].$$

与“广义池”不同的是，其设置了权重的一个先验随机过程：

$$x_t = (1 - \rho)\mu + \rho x_{t-1} + \sqrt{1 - \rho^2} \sigma \varepsilon_t, \\ \varepsilon_t \sim iid N(0, 1), x_0 \sim N(\mu, \sigma^2), \\ \lambda_t = \Phi(x_t),$$

而权重的在 $t - 1$ 、 t 时刻的后验如下所示，而密度序列使用Bootstrap来近似；最后对后验概率求期望得到权重的估计。文章对向前 h 步的权重估计也进行了讨论。

$$\begin{aligned}
 & p(\lambda_t | \theta, \mathcal{I}_{t-1}^{\mathcal{P}}, \mathcal{P}) \\
 &= \int p(\lambda_t | \theta, \lambda_{t-1}, \mathcal{P}) p(\lambda_{t-1} | \theta, \mathcal{I}_{t-1}^{\mathcal{P}}, \mathcal{P}) d\lambda_{t-1} \\
 & p(\lambda_t | \theta, \mathcal{I}_t^{\mathcal{P}}, \mathcal{P}) \\
 &= \frac{[\lambda_t p(y_t | y_{1:t-1}, \mathcal{M}_1) + (1 - \lambda_t)p(y_t | y_{1:t-1}, \mathcal{M}_2)] p(\lambda_t | \theta, \mathcal{I}_{t-1}^{\mathcal{P}}, \mathcal{P})}{p(y_t | \theta, \mathcal{I}_{t-1}^{\mathcal{P}}, \mathcal{P})}
 \end{aligned}$$

- **组合实证：**

数据：1992-2011产出增长、通胀等宏观经济数据

方法：个体方法是两个不同的DSGE（动态随机一般均衡模型），与等权组合、BMA（贝叶斯平均）、最优（静态）池、动态模型平均等组合方法对比。

结论：动态池在面对冲击时权重变化惯性小，易于对模型预测结果的相对变化作出反应；在以对数得分表示的结果中，动态池略优于等权组合，大优于其它组合（把握不好权重变化规律，不如一视同仁）。文章也说明了本方法在政策分析的应用。

Dynamic Bayesian predictive synthesis in time series forecasting (McAlinn and West, 2019)

- **组合方式：**本文提出了一个BPS（贝叶斯预测合成）框架，其对当前时刻的概率预测可以表示为下式：

$$p(y_t | \Phi_t, y_{1:t-1}, \mathcal{H}_{1:t}) \equiv p(y_t | \Phi_t, \mathcal{H}_t) = \int \alpha_t(y_t | \mathbf{x}_t, \Phi_t) \prod_{j=1:J} h_{tj}(x_{tj}) dx_{tj}$$

这里 h 指个体预测模型（文中是代理模型，agent）， α 是 y 在给定 x 的条件下 y 先验的条件概率密度函数（合成函数，模型的主要目标）， Φ 是其中的时变参数， h 是当前预测的密度。。进一步，使用动态线性模型（DLM）来作为预测合成的方法，式中主要量可以如下表示：

$$\alpha_t(y_t | \mathbf{x}_t, \Phi_t) = N(y_t | \mathbf{F}'_t \boldsymbol{\theta}_t, v_t) \quad \text{with} \quad \mathbf{F}_t = (1, \mathbf{x}'_t)' \quad \text{and} \quad \boldsymbol{\theta}_t = (\theta_{t0}, \theta_{t1}, \dots, \theta_{tJ})'$$

$$\begin{aligned}
 y_t &= \mathbf{F}'_t \boldsymbol{\theta}_t + v_t, \quad v_t \sim N(0, v_t), \\
 \boldsymbol{\theta}_t &= \boldsymbol{\theta}_{t-1} + \boldsymbol{\omega}_t, \quad \boldsymbol{\omega}_t \sim N(0, v_t \mathbf{W}_t)
 \end{aligned}$$

$$p(\mathbf{x}_t | \Phi_t, y_{1:t-1}, \mathcal{H}_{1:t}) \equiv p(\mathbf{x}_t | \mathcal{H}_t) = \prod_{j=1:J} h_{tj}(x_{tj})$$

生成预测时通过MCMC依次采样 Φ, θ, y 来实现。考虑到短期模型和长期模型有各自的适用性，文中尝试了提前1步和4步的预测。

- **组合实证：**

数据：美国宏观经济数据，1961年第一季度至2014年第四季度美国经济的年通货膨胀率(P)、短期名义利率(R)和失业率(U)

方法：个体方法为四个DLM代理模型（变量不同），将BPS与BMA、等权池、对数池比较，使用指标为其它方法与BPS密度比的对数

结论：BPS能够快速适应个体模型预测的变化而修改权重，预测的标准差较低

随便想想

所看论文主线是如何进行概率预测，大多数是如何安排线性组合的权重，从定值转向时变权重。所用方法也由直接优化对数分数转向贝叶斯方法（对数分数仍是一常用评价指标）。

Dynamic Bayesian predictive synthesis in time series forecasting (McAlinn and West, 2019) 一文在结论中提出，本文的方法可以用在包括金融(例如股票、指数和债券)、业务(例如产品需求和收益)、气象和风险(例如地震和环境风险)等领域。**对于多变量综合、非正态预测和离散数据，以及缺失或不完整/部分预测，都需要方法论上的扩展。**据此，有下列想法：

- 所见论文的实证都基于宏观经济或金融数据，（一般基于正态假设的个体模型进行组合），那对于不适于用正态假设的数据（如intermittent demand），是否对于概率组合预测需要有较大方法上的变化；
- 这些论文的组合预测都是基于一条时间序列，那么如果基于数据集，利用数据集的信息对概率组合预测是否有更好的效果，即对于数据集的概率预测，是每条单独训练权重，还是需要有一个共通的模式生成各序列的权重； global combination ensemble
- 多数都是线性权重组合的概率预测，那么非线性的组合方式是否还要进一步思考；
- M5的不确定性预测似乎没有考虑方法组合的问题，那么，假设组合前几名的预测结果（不同设置的网络），或者将网络与统计方法组合，能否获得严格更好的效果，或者利用较简单的统计方法的组合以尽力接近网络的结果？
- 效用？