

2022.5.5

LSTM与lightGBM基准预测

数据输入

训练集的时间跨度为756天 (27*28)，将其分成27个不重叠的时间窗。对于每个时间窗，时间窗自身用于计算预测误差，其对应的输入特征x如下：

- 价格特征：原始价格、相对同cat内的最大值的比例、相对同dept内的最大值的比例；
- 日历特征：日期在一年中的比例、星期几（可表示成在一周的比例）、距开售第一天的距离
- 销售特征：原始销量28期滞后、7期移动平均（28期滞后的）、28期移动平均（28期滞后的）
- 节假日（event name 31类，嵌入后6类；event type 5类，嵌入后2类）
- SNAP
- 与间断相关的特征：上两个正销售额间的距离、距上一个正销售的距离
- id: store (10--4)、state (3--2)、cat (3--2)、dept (7--3)、item (3049--30) 的id

模型设置

LSTM的网络设置与上次汇报相同，**嵌入层——Dropout——LSTM层——Dropout层——线性层**，输出负二项分布的两个参数，分位数预测通过计算分布的分位数得到（用所求分布抽取1000个数据，计算样本分位数）。

lightGBM使用python的 `lightgbm` 包实现，输入特征与LSTM相同，预测时逐期输入特征逐期预测。其支持对pinball loss进行优化。

基准预测结果与组合结果

基准预测

以下是各方法基准预测的对比（在元学习的test set上）：LSTM与LightGBM并没有经过调参处理，预测结果并不是很突出，没有太多的完全占优次数，在各个分位数预测预测的结果都属于较好，但不能好过nb_undamped 这种只依赖历史销量数据的统计方法结果。可能原因是：需要调参；使用数据的时间范围需要扩容（但是仅考虑近两年数据的原因主要在于个人电脑的内存限制）；网络结构等。但不排除就是nb_undamped在此数据上较好的可能性（因为自己不好实现M5排名靠前选手的方法）。

这两种基准方法是否还需要继续优化？

分位数	0.01	0.025	0.165	0.25	0.5	0.75	0.835	0.975	0.99	平均秩
quantGAM	0.0146	0.0368	0.2336	0.3378	0.5638	0.5554	0.4769	0.1592	0.0887	8.22
VZ	0.0143	0.0356	0.2275	0.3289	0.5374	0.5320	0.4551	0.1454	0.0785	4.83
WSS	0.0143	0.0356	0.2270	0.3322	0.5740	0.5672	0.4745	0.1520	0.0754	5.61
poisson_static	0.0409	0.0706	0.2692	0.3631	0.5448	0.5434	0.4786	0.2146	0.1491	10.22
poisson_damped	0.0243	0.0495	0.2347	0.3243	0.4974	0.4926	0.4279	0.1683	0.1084	6.44
poisson_undamped	0.0249	0.0497	0.2322	0.3201	0.4915	0.4906	0.4306	0.1880	0.1318	6.33
nb_static	0.0144	0.0358	0.2295	0.3382	0.5878	0.6205	0.5292	0.1498	0.0759	7.11
nb_damped	0.0150	0.0366	0.2206	0.3179	0.5172	0.5129	0.4428	0.1553	0.0839	5.33
nb_undamped	0.0144	0.0356	0.2164	0.3105	0.4958	0.4979	0.4359	0.1681	0.1043	3.61
LSTM	0.0144	0.0358	0.2206	0.3178	0.5172	0.5167	0.4426	0.1444	0.0760	3.72
lgb	0.0144	0.0361	0.2260	0.3174	0.5094	0.5167	0.4477	0.1507	0.0815	4.56

组合结果

根据之前的经验，使用固定效应惩罚系数为50的分位数回归进行回归组合，结果如下：

分位数	0.01	0.025	0.165	0.25	0.5	0.75	0.835	0.975	0.99
面板回归 (11模型)	无	0.6167	0.2150	0.3064	0.4890	0.4892	0.4204	0.1340	0.0695
加权平均 (11模型)	0.0155	0.0376	0.2210	0.3145	0.5035	0.5003	0.4269	0.1342	0.0696
简单平均 (11模型)	0.0171	0.0389	0.2208	0.3147	0.5046	0.5010	0.4270	0.1337	0.0694
面板回归 (9模型)	0.0143	0.0356	0.2168	0.3091	0.4915	0.4897	0.4217	0.1351	0.0702
面板回归 (10模型)	0.0143	0.0356							

- 在0.975、0.99右侧极端分位数上简单平均最好，但差距并不大；
- 中间分位数组合方法最好；
- 左侧两个极端分位数的回归组合属于异常情况：0.025运行代码时报 singular matrix 警告，预测系数不正常；而0.01运行代码时触发 fatal error。可能原因是，新引入的两个方法在0.01分位数与0.025分位数的预测结果基本均是取0，引起了矩阵奇异的问题。

一个权宜处理方法：将0.025、0.01的分位数组合仅引入LSTM模型，结果改善。

组合系数结果如下：

分位数	0.01	0.025	0.165	0.25	0.5	0.75	0.835	0.975	0.99
截距	~	0.9716	-0.0008	0.0000	0.0002	0.0047	-0.0090	0.1329	0.1566
quantGAM	~	0.6030	0.0004	0.0002	0.0095	0.0409	0.0779	0.1231	0.1325
VZ	~	0.0811	0.0161	0.0111	0.0086	0.0321	0.1095	0.1280	0.0684
WSS	~	-0.0759	0.2143	0.1702	0.0291	0.0066	0.0075	0.0548	0.0668
poisson_damped	~	0.4835	-0.0241	-0.0116	-0.0087	-0.0358	-0.1015	-0.1819	-0.1920
poisson_undamped	~	-0.1566	-0.0012	0.0000	0.0750	0.1650	0.1873	0.1884	0.1930
poisson_static	~	1.2360	0.0631	0.2437	0.5476	0.5957	0.4526	0.1044	0.0721
nb_static	~	-1.8556	0.0976	0.0060	-0.0397	-0.0094	-0.0118	0.0291	0.1112
nb_damped	~	0.0530	0.0259	0.0182	0.0048	0.0007	0.0131	0.0438	0.0326
nb_undamped	~	-0.3129	0.3653	0.1993	0.0012	-0.0040	0.0032	0.0564	0.0604
lstm	~	1.2869	0.5046	0.3303	0.2165	0.0679	0.1104	0.0929	0.0675
lgb	~	0.0000	0.2697	0.2226	0.1164	0.1295	0.1502	0.2563	0.2676

只10模型的系数修改：

分位数	0.01	0.025	0.165	0.25	0.5	0.75	0.835	0.975	0.99
截距	0.0000	-0.0008							
quantGAM	0.0000	0.0001							
VZ	0.6147	0.0720							
WSS	0.5442	0.8208							
poisson_damped	0.0000	0.0000							
poisson_undamped	0.0000	-0.0005							
poisson_static	0.0000	0.0004							
nb_static	0.0000	0.0017							
nb_damped	0.0000	0.0018							
nb_undamped	0.0000	0.0864							
lstm	0.0000	0.6115							
lgb									

今后计划

尝试基于LSTM的时变分位数组合：

- 考虑时变权重与截距引入的问题；
- 使用特征的问题：自选特征或者参考 Ma & Flides (2021) 的设置，使用基于网络提取的特征。