

2021.11.4

概率预测

主要关注内容：概率预测的实现及评估方法，希望对概率预测有些概念。具体领域包括**需求预测**（特别希望看到intermittent demand）以及**电力预测**（有GEFCcom2014、GEFCom2017比赛的支持）。前者为主。

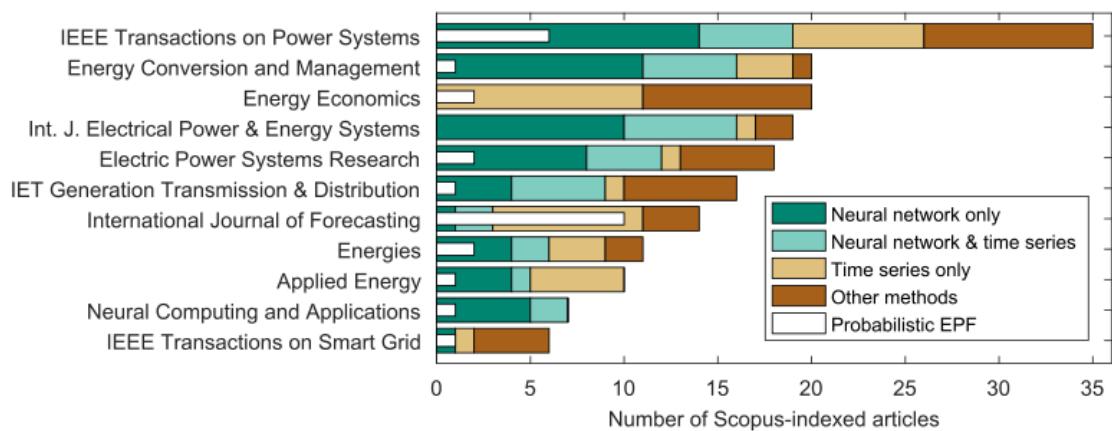
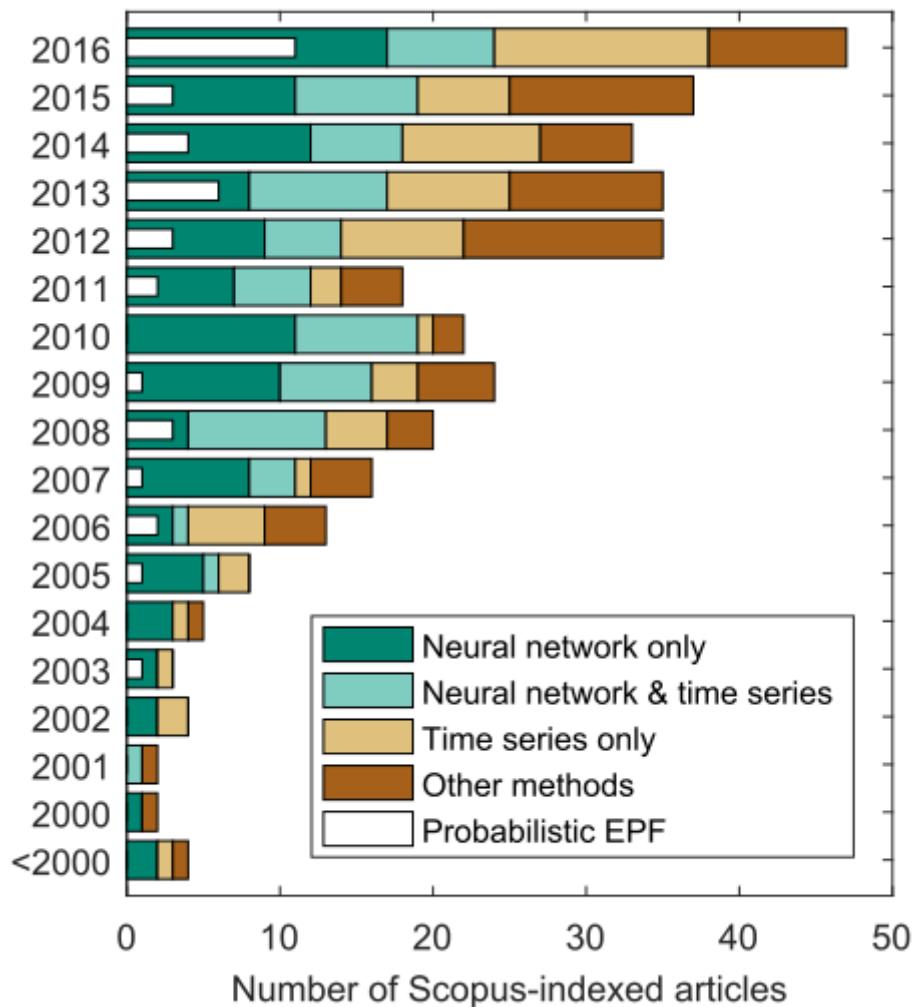
综述：*Recent advances in electricity price forecasting: A review of probabilistic forecasting*

(Jakub Nowotarski, Rafał Weron, 2018) (Renewable and Sustainable Energy Reviews)

本文是综述文章，从电价预测与GEFCcom2014结果展开。

研究情况

在电价预测领域，研究逐年增长，概率预测也基本如此（但比重不大，最高也就20%）。该领域预测方法以神经网络为主。而主要期刊的方法分布也呈现出学科背景的差异：偏工程的期刊更重视网络模型的使用，而偏经济的期刊则以时间序列统计方法为主；此外，IJF最关注概率预测问题。



GEFCom2014比赛的代表方法

- 第一名：对不同任务使用3种不同模型，分别是：**广义加性模型（GAM）&分位数回归；分位数回归平均组合**（自回归、回归、GAM、随机森林、梯度提升等13模型组合）；**核分位数Lasso回归**。
- 第二名：以**分位数回归平均（QRA）**为主，分为**点预测**（两个结构相同、样本不同自回归）、**预过滤、分位数回归建模**（结合之前自回归与外生变量）和**后处理**（平滑分位数曲线以避免分位数交叉）四步。
- 第三名：一个仅有5个sigmoid激活函数的MLP（单隐藏层5个神经元），假设误差服从正态分布。
- 第四名：一个带正则项的分位数回归，交叉验证选择变量，乘子交替方向法(ADMM)求解损失函数最小化。

(这个时期，还是统计方法更能占优，与对Kaggle比赛评估的论文 Kaggle forecasting competitions: An overlooked learning

opportunity (Bojer & Meldgaard, 2020) 结果相近)

概率预测概述

作者认为概率预测方法可分为四类：

- **历史模拟或经验预测区间**：举例为 Value at Risk (VaR) 的历史模拟，独立于模型，计算误差经验分布的样本分位数。
- **基于分布的概率预测**：对于以正态误差驱动的模型 (ARIMA等)，密度预测可以设置为近似误差密度的高斯分布。（个人感觉之前所看概率预测组合中所用的单一方法基本都属于此，比如AR、VAR、GARCH类、基于经济理论的一般均衡模型（统计本质还是线性回归）。）
- **Bootstrap预测区间**：先估计模型的参数与残差样本，之后使用参数与残差不断生成伪数据，用伪数据拟合模型并预测，得到预测区间。（常见于神经网络中，应该是先做了点预测再考虑误差）
- **分位数回归平均**：直接估计分位数与自变量的关系，不借助分布。

评价与指标

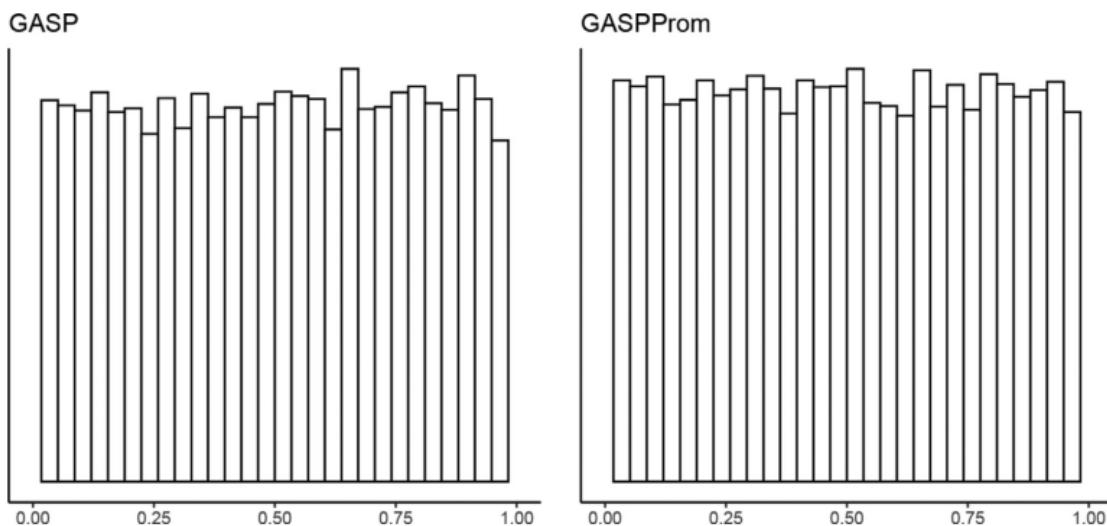
(上一周分享应该也提到了这个内容)

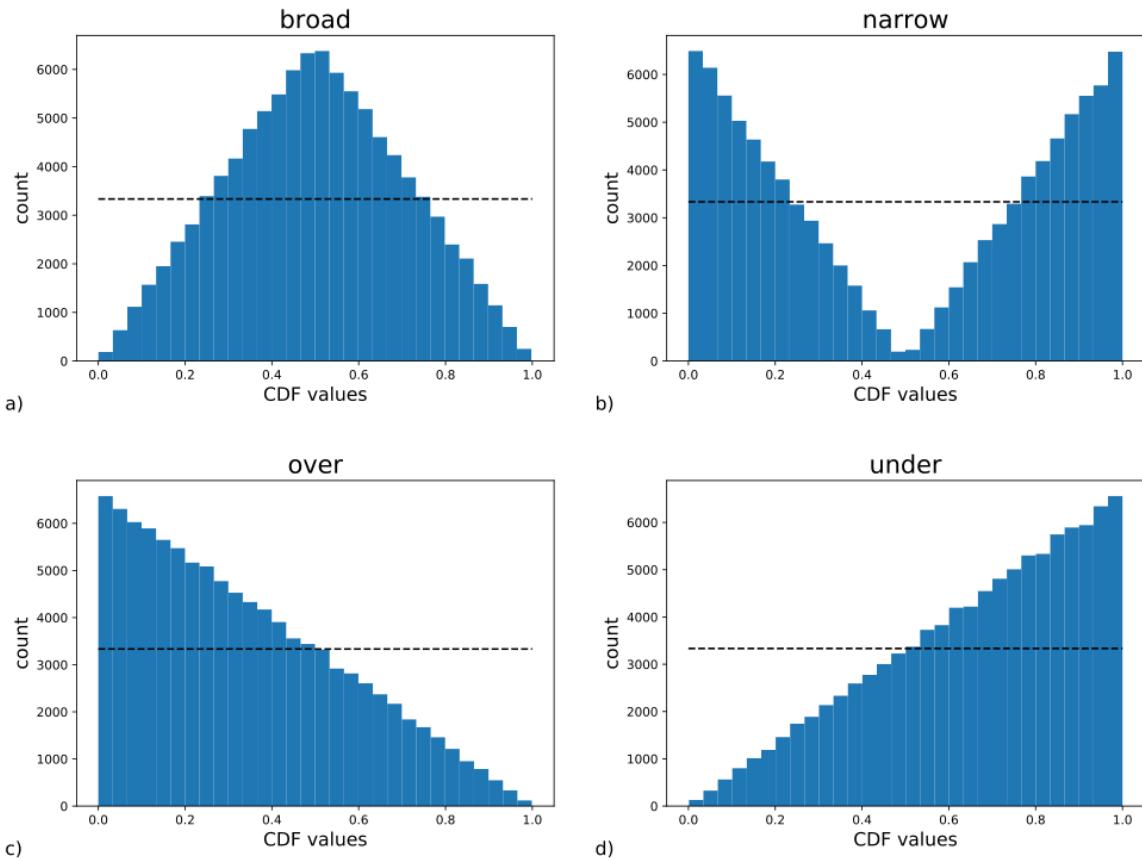
Gneiting et al. (2014) 指出概率预测的目标是 “**maximize the sharpness** of the predictive distributions, **subject to reliability**” 。

- **Reliability**：文献中又称 calibration 或 unbiasedness，指预测与观测的一致性（如，90% 预测区间覆盖90% 观测值）。
- **Sharpness**：衡量预测区间有多紧密的覆盖真实数据，希望预测宽度尽量窄。（预测的浓度）

(或许可以和效度与信度类比？)

Reliability的检验：Kupiec test (非条件覆盖检验，构造预测值是否击中真实区间的示性量，再进行似然比检验)；Christoffersen test (条件覆盖检验，在前者基础上引入条件、独立性检验)；也可用拟合优度检验；使用概率积分变换 (PIT) 进行可视化检验，要求最后出现的直方图符合一个 [0,1] 均匀分布。（最后一个还很常用）





Sharpness评价: 与评分规则（损失函数？）挂钩，之前提到的对数分数属于此。

Pinball Loss: 分段线性损失，也是分位数回归中要最小化的函数。

$$Pinball(\hat{Q}_{P_t}(q), P_t, q) = \begin{cases} (1 - q)(\hat{Q}_{P_t}(q) - P_t), & \text{for } P_t < \hat{Q}_{P_t}(q), \\ q(P_t - \hat{Q}_{P_t}(q)), & \text{for } P_t \geq \hat{Q}_{P_t}(q), \end{cases}$$

Winkler score: 一个可以同时评估Reliability和区间宽度的指标：

$$Winkler_t = \begin{cases} \delta_t, & \text{for } P_t \in [\hat{L}_t, \hat{U}_t], \\ \delta_t + \frac{2}{\alpha}(\hat{L}_t - P_t), & \text{for } P_t < \hat{L}_t, \\ \delta_t + \frac{2}{\alpha}(P_t - \hat{U}_t), & \text{for } P_t > \hat{U}_t, \end{cases}$$

Continuous Ranked Probability Score (CRPS): 为解决对数得分不够稳健的问题，使用此评分。积分改成求和就是离散化的指标DRPS。

$$CRPS(\hat{F}_{P_t}, P_t) = \int_{-\infty}^{\infty} (\hat{F}_{P_t}(x) - \mathbb{1}_{\{P_t \leq x\}})^2 dx,$$

以上指标可以作为评价标准，也可以作为训练中优化的函数。

上次讲论文中有提到结论 **Statistical methods is enough, emphasise sharpness is not recommended** (Mitchell and Wallis, 2011)；问题何在？

需求概率预测

Forecasting the intermittent demand for slow-moving inventories: A modelling approach

(Snyder et al., 2012) (International Journal of Forecasting)

假设了两个间断需求模型：

1. 时间连续，交易零星：每个时期内交易次数服从泊松分布，考虑交易规模服从对数序列，则每个时期的综合需求量呈**负二项分布**；
2. 时间离散，被分成大致相等几段：**hurdle shifted Poisson process**（原始的泊松分布向正值平移1，然后概率为1-p取0, p取正值）

此外还假设了分布均值随时间变化的情况，分为3类：

1. Static: 恒定不变
2. Damped dynamic: 平稳过程，受均值与真实值的一期滞后影响
3. Undamped dynamic: 非平稳过程

Table 2

Recurrence relationships for the mean.

Relationship	Recurrence relationship	Restrictions
Static	$\mu_t = \mu_{t-1}$	
Damped dynamic	$\mu_t = (1 - \phi - \alpha)\mu + \phi\mu_{t-1} + \alpha y_{t-1}$	$\mu > 0, \phi > 0, \alpha > 0$ $\phi + \alpha < 1$
Undamped dynamic	$\mu_t = \delta\mu_{t-1} + \alpha y_{t-1}$	$\delta > 0, \alpha > 0$ $\delta + \alpha = 1$

对hurdle shifted Poisson process，其正值概率p也可以按如上的方式时变。以上模型使用极大似然估计，并在预测中前向模拟以获得预测序列的分布。

此外作者提到了一个基于Croston的概率假设 (Hyndman et al, 2008)，其认为时间间隔服从负二项分布，正需求服从shifted poisson分布，两个分布参数预测时用简单指数平滑更新（需要注意：向前预测时会出现长期收敛到定值的问题！）

概率预测的评价指标为预测似然分数(PLS)与DRPS (CRPS的离散版本)。

作者认为此方法对库存管理是有用的。

Intermittent Demand Forecasting with Deep Renewal Processes

(Türkmen et al., 2019) (Arxiv文章，貌似没见刊，而且正文仅4页，不够完善；但思路可以参考，因为intermittent demand 概率预测实在不多)

时间间隔服从负二项分布（参数与上一时刻的时间间隔估计有关），需求大小服从泊松分布（参数与上一时刻的需求大小估计有关），而在在Croston中估计是由指数平滑完成的。据此，其将上述模型改为：

时间间隔服从一非负离散分布（负二项分布）或连续分布（伽马分布），需求大小服从一非负离散分布（负二项分布），而分布所需的参数等性质则依赖于LSTM生成。

$$Q_i \sim \mathcal{NN}(g_q(\mathbf{h}_i)) \quad M_i \sim \mathcal{NN}(g_m(\mathbf{h}_i)) \quad \mathbf{h}_i = LSTM_{\Theta}(\mathbf{h}_{i-1}, Q_i, M_i)$$

DeepAR: Probabilistic forecasting with autoregressive recurrent networks

(Salinas et al., 2020) (International Journal of Forecasting)

提出**DeepAR**解决零售业预测问题（可能是M5选手参考的文章之一？）

作者认为贡献在于：（1）提出了用于概率预测的RNN，结合计数数据负二项似然；（2）表明基于深度学习的方法可以有效地解决概率预测问题。而作者认为的方法优势有4点：

- 捕捉季节性、相关性所需人工干预少
- 以蒙特卡洛方式采样预测，可计算预测范围内任何子范围的一致估计
- 通过类似的项目可以预测较短时间序列
- 不假设高斯噪声，可以选择其它统计分布

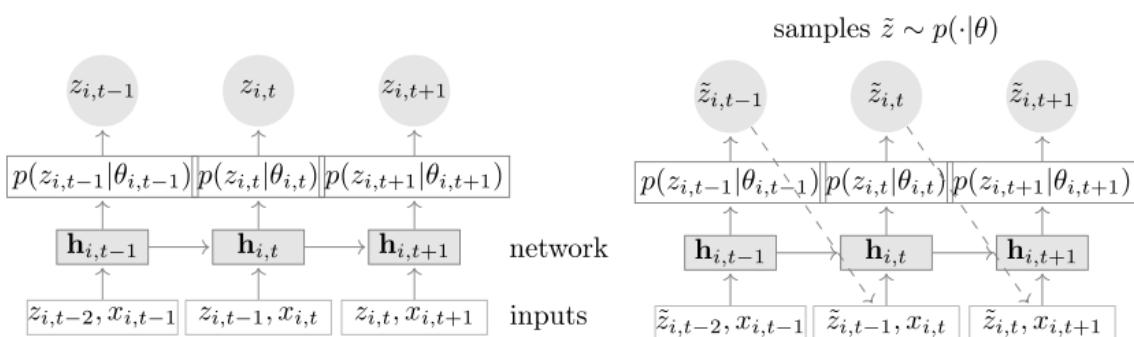
预测方法：

目标是估计时间序列未来的条件分布（给定过去的序列与外生变量）

$$P(\mathbf{z}_{i,t_0:T} | \mathbf{z}_{i,1:t_0-1}, \mathbf{x}_{i,1:T})$$

训练与预测时基于如下的自回归循环神经网络。左侧是训练部分，接受前一时刻的输出以及数据信息，训练概率分布，生成预测；右侧是预测部分，每次预测时将预测结果代入下一时刻进行迭代，生成一条预测序列，再重复多次；实践中保持所有训练样本的条件和预测范围的总长度T和相对长度都是固定的。

（这里有一个小问题：训练时上一时刻序列值是真值，但预测时只能由上一时刻预测值产生之后的预测，造成一个脱节的问题；但是作者认为这对本文的结果影响不大。）



文中考虑了正态与负二项两种分布，但是其它分布也可以使用。分布的参数与 h 挂钩，通过一个连接函数与 h 的线性表示相连（类似于广义线性回归）。优化的损失函数为对数似然函数。

学习中不需要细致的超参调整，即可用于不同数据集，而且不需要大量的数据集（文中认为几百条序列就可以应用）。

A score-driven model of short-term demand forecasting for retail distribution centers

(Hoeltgebaum et al., 2021) (Journal of Retailing)

所用方法为一个**广义自回归分数模型** (GAS)；针对的数据为有一定汇总的销售数据，故未考虑间断性，但是考虑了数据的偏态，文中使用的是对数正态分布。

模型的结构如下所示，这里假定均值时变而方差不变。（方差时变的模型作者也尝试了，但估计结果一般。）方程通过ARMA的平稳可逆条件即可保证模型的平稳性。

$$\log q_t = \mu_t + \epsilon_t$$

$$\mu_t = \omega + \sum_{i=1}^p \phi_i \mu_{t-i} + \sum_{j=1}^q \theta_j \epsilon_{t-j}$$

$$\text{where } \epsilon_t \sim \text{NID}(0, \sigma^2).$$

$$p(q_t | \mathcal{F}_{t-1}) = \frac{1}{q_t \sigma \sqrt{2\pi}} e^{-\frac{(\ln(q_t) - \mu_t)^2}{2\sigma^2}}, \quad t = 1, \dots, T$$

此外，通过引入连接函数的方式，可以将外生变量纳入模型中：

$$E(q_t | \mathcal{F}_{t-1}) = e^{\mu_t + \gamma' \Lambda_t + \frac{\sigma^2}{2}}$$

所考虑的外生变量包括星期、假日、价格、促销行为哑变量等。

预测时也是用蒙特卡洛法不断采样去得到分布。、

实证：使用巴西一家大型零售企业的数据，总体销售层次；与线性回归、ETS、神经网络进行比较，点预测占优，而且reliability和sharpness较好。

Demand Forecasting of Individual Probability Density Functions with Machine Learning

(Wick et al., 2021) (Operations Research Forum)

主要的方法是 **Cyclic Boosting**，一个可解释的机器学习方法。

文中使用负二项分布，对两个参数（均值与方差）分别估计。均值解释成各因子的乘积，而特征又循环的由g生成。通过迭代得到估计。另一个参数通过优化负对数似然得到。

$$\hat{\mu}_i = c \cdot \prod_{j=1}^p f_j^k \quad \text{with } k = \{x_{j,i} \in b_j^k\}$$

$$g_{j,t}^k = \frac{\sum_{\substack{x_{j,i} \in b_j^k \\ x_{j,i} \in b_j^k}} y_i}{\sum_{\hat{\mu}_{i,\tau}} \hat{\mu}_{i,\tau}} \quad \text{where } f_{j,t}^k = \prod_{s=1}^t g_{j,s}^k$$

为了避免“时间混杂” (Temporal Confounding) 的问题，**不直接使用任何自身的滞后项进行建模**，以保证可解释性（与M5第二名的特征选择类似）；而使用指数平滑来捕获误差修正项，以使用序列自身的信息优化结果。

使用了M5食物的100条序列进行实证，发现由于零膨胀等问题，负二项分布在分布两端的预测不佳，但比泊松模型强很多。

其它领域概率预测

Density forecasting of daily electricity demand with ARMA-GARCH, CAViaR, and CARE econometric models

(Can Bikcoraa, Lennart Verheijenb, Siep Weilanda, 2018) (Sustainable Energy, Grids and Networks)

电力预测，使用模型：

- ARIMAX-GARCH：交叉验证来筛选模型，估计方法尝试了迭代最小二乘、非线性最小二乘和拟极大似然，使用蒙特卡洛前向传播方法估计密度（根据模型生成大量前向预测）。
- 分位数回归：法1是CAViaR，对过去的测量值和分位数本身的过去值进行分位数回归；法2是CARE，是法1的期望分位数回归

Probabilistic Forecasting with Spline Quantile Function RNNs

(Gasthaus et al., 2019) the 22nd International Conference on Artificial Intelligence and Statistics(会议论文)

使用方法：单调回归样条对条件分位数函数进行概率建模；样条的形状由神经网络 (RNN)参数化；神经网络的参数是通过最小化连续排序概率得分来学习的(CRPS)。

在模拟和电力、交通、wiki、域名四个数据集进行了实验。（但预测结果的评估还是用的点预测指标）

Uncertainty analysis of wind power probability density forecasting based on cubic spline interpolation and support vector quantile regression

(He et al., 2021) (Neurocomputing) 风电功率预测

使用方法：**三次样条插值+支持向量回归**，利用得到的分位数使用核密度估计；样条插值目的是对特异点进行调整以使模型预测结果更优。（疑问：这会不会影响概率预测对极端值的把握，从而使概率预测对极端情况更不重视）

考虑了点预测与区间预测的评价；使用预测区间归一化平均宽度(PINAW)和预测区间覆盖概率(PICP)来度量区间预测；为进一步衡量，将二者组合成CWC指标（注意：在第一篇综述中明确指出这个指标有问题！）

个人想法

还是想以intermittent demand为主进行概率组合预测。而individual model或许可以如下尝试：

历史模拟或经验预测区间：可以用WSS与VZ等基于历史数据的Bootstrap方法进行概率预测生成。

基于分布的概率预测：

- 基于负二项/tweedie/零膨胀等分布的模型，想尝试DeepAR（M5的头部模型主要是LGBM和DeepAR，后者点预测第三名、不确定预测第四名都有应用）；
- 还可以尝试 *Forecasting the intermittent demand for slow-moving inventories: A modelling approach* 一文的方法；
- 考虑需求间隔&需求规模 (Croston系列) 或者需求发生概率&需求规模 (TSB类) 构造两个概率，结合基本模型的指数平滑更新方式进行概率预测，而基本更新方式（分布参数的指数平滑）也可能涉及SBA、SBJ、mSBA、mTSB等.....

分位数回归平均：感觉可以直接用相关外生与滞后变量进行分位数回归，得到分位数估计。可以参考GEFCom2014比赛的头部模型等。（2017比赛的相关内容还没关注）

同时，对于概率预测组合，可能有以下新情况：

- 不同分布类型的概率进行组合——会对组合的推导产生影响吗
- 参数模型与非参数模型进行组合——使用非参结果的“经验分布”，或者干脆组合方式进行调整

